

강화학습 프로젝트


Study Scheduler RL

강화학습 기반 학습 스케줄러

학번: A72047

이름: 노태호

GitHub: <https://github.com/NohTaeHo1/rl-final-studyscheduler>



목차

CONTENTS

- | | |
|----|-------------------------------|
| 01 | 문제 정의와 동기 |
| 02 | MDP 설계: State/Action/Reward |
| 03 | 환경 및 시뮬레이션 데이터셋 |
| 04 | 알고리즘: Baseline & DQN |
| 05 | 실험 프로토콜 및 평가 지표 |
| 06 | 결과: Return·Retention·Coverage |
| 07 | Collapse 분석 |
| 08 | 결론 및 개선 방향 |

RL PROJECT

Study Scheduler RL

강화학습 기반 학습 스케줄러

01

문제 정의와 동기

제한된 학습 시간 안에서 신규 학습과 복습을 어떻게 배분할 것인가?
목표는 backlog 최소화가 아니라 retained knowledge coverage backlog의 균형을 찾는 것이다.

“학습 스케줄링”


신규 학습과 복습의 균형 문제

신규 학습 신규 학습으로 coverage 확대

복습 복습으로 backlog 감소

장기 기억 retention 장기 유지


좋은 스케줄러의 균형



왜 이 주제인가?

실제 사내 데이터를 이용할 수 없는 상황에서 제대로된 주제로 RL을 해보고 싶었고, 실제 내 삶에 도움이 조금이라도 될만한 모델을 만들길 원했다.
RL을 적용해본 것이 아니라, 실제 학습의 신규 학습복습 시간 배분 문제를 다루기 위해 선택했다.

신규 학습 ↔ 복습



개인적 동기 새 학습을 늘리면 복습이 밀리고, 복습만 하면 학습 범위가 늘지 않는다 이 균형을 정상화하고 싶었다

왜 RL 오늘의 배분이 내일의 backlog·retention을 바꾸는 순차 의사결정 문제 → rule보다 policy learning이 적합

왜 simulator 대규모 학습 로그 수집이 어려워, retention·backlog·coverage 상충을 담은 비교용 환경을 직접 설계했다

02

MDP 설계

학습 스케줄링을 마르코프 결정 과정(MDP)으로 정의한다.
에이전트는 매일 상태를 관찰하고 학습·복습 행동을 선택한다.

State · Action · Reward



State day progress · item-level knowledge · backlog · coverage ratio/gap · recent review (정규화)

Action 하루 4개 학습 블록을 신규 학습/복습 후보에 배정 (discrete scheduling action)

Reward retention 보상 – backlog penalty – coverage_gap_penalty



03

스케줄러 환경과 행동

외부 raw dataset 없이 item의 coverage-review backlog-retention을 simulator 상태로 관리한다.
전이는 하루 단위로 발생하며, 신규 학습은 coverage를 늘리고 복습은 backlog-retention decay를 완화한다.

하루 = 4 × 15분 블록



환경 · 데이터셋

Synthetic simulator

Horizon 365일

1 transition / day

4 × 15분 블록

외부 raw 데이터 없음

feature 집계·정규화

04

Reward 설계

$$R(t) = R_{\text{retention}}(t) - \lambda_b \cdot \text{Backlog}(t) - \lambda_c \cdot \text{CoverageGap}(t)$$

coverage reward v2를 더했지만, episode_return_mean 단독 selection으로 no-learning collapse는 완전히 제거되지 않았다.

coverage reward v2



Retention (+) retained knowledge에 비례한 양(+)의 보상

Backlog (−) 미복습 누적(backlog)에 대한 페널티

Coverage v2 coverage_gap_penalty로 no-learning 무페널티 방지

Selection episode_return_mean (scalar 합산 지표)




05

Baseline 정책

5개 휴리스틱 baseline을 동일 환경·seed에서 비교한다.
신규 학습과 복습을 배분하는 방식이 정책마다 다르다.

5 Heuristic Baselines



random·equal_split·fixed_ratio·review_first coverage=1.0 이지만 backlog=160 누적, return -4.4k~-4.5k

greedy_immediate_gain backlog=7.93 · coverage=0.067 · retained knowledge=2.73


관찰 greedy_immediate_gain은 coverage는 낮지만 retained knowledge·AUC에서 DQN보다 높았다

06

DQN 에이전트

DQN으로 매일의 학습-복습 행동 가치를 추정한다.
replay buffer와 target network로 학습을 안정화한다.

DQN + replay + target net



Q-network state에서 각 scheduling action의 Q-value를 예측

학습 replay buffer sample로 Bellman target 계산해 업데이트 (target network)

Selected config config_id=2 · lr=0.001 · γ =0.95 · hidden_dim=256 · ϵ_{end} =0.05

Selection episode_return_mean으로 config 선택 → seed 100104에서 최종 재실행

07

실험 프로토콜

GPU NVIDIA H100 NVL · Horizon 365일 · Final seeds 100104
 지표: episode return · retained knowledge(+AUC) · backlog · coverage ratio · collapse rate
 95% CI = $\text{mean} \pm t(0.975, 4) \cdot \text{SD} / \sqrt{5}$ (n = 5 seeds)


H100 학습 · 평가 프로토콜

 Baseline	 DQN Sweep	 DQN Final	 Evaluation
5 seeds 집계	24 configs × 3 seeds × 100 ep	5 train seeds × 150 ep	seed당 5 eval episodes 평균

08

결과 ①: Return

DQN selected (dqn_best, config_id=2)는 episode return 기준 최고값(-1169.654)이다.
그러나 이 향상은 retained knowledge 증가가 아니라 backlog 회피에서 주로 발생했다.



Episode return by policy 낮을수록 나쁨

정책별 Episode Return · Backlog

정책	Episode return	Backlog
dqn_best	-1169.7	1.1
greedy_immediate_gain	-1356.3	7.9
review_first	-4388.7	160
equal_split	-4532.5	160
fixed_ratio	-4532.7	160
random	-4536.4	160

→ episode return 1위가 곧 좋은 스케줄러는 아니다 coverage:retention과 함께 해석 (다음 슬라이드)

09

결과 ②: Retained

최종 retained knowledge는 greedy_immediate_gain이 가장 높다.
DQN은 return 1위였지만 retention에서는 baseline에 밀린다.


greedy » DQN

greedy_immediate_gain: final retained knowledge = 2.730

DQN(dqn_best): 0.394 ± 1.094 (mean $\pm$ 95% CI; SD=0.881)

retained knowledge·AUC 모두 greedy가 DQN보다 높음 (877.204 vs 12.370)

선택된 DQN은 backlog를 줄인 정책이라기보다 학습을 거의 하지 않은 정책에 가까움




Final retained knowledge by policy


10

결과 ③: 실패 모드

대부분의 baseline은 coverage=1.0이나 backlog=160으로 누적된다.
DQN은 backlog=1.07로 낮지만 coverage=0.007 학습 회피에 가깝다.



Final backlog by policy



Final coverage ratio by policy

random·equal_split·fixed_ratio·review_first: coverage=1.0, backlog=160
greedy_immediate_gain: coverage=0.067, backlog=7.93 (다른 baseline과 구별됨)
DQN(dqn_best): backlog=1.07로 낮지만 coverage=0.007 → 사실상 학습 회피
→ 낮은 backlog만으로는 no-learning 실패 모드를 가릴 수 있다

11

결과 ④: Collapse

선택 기준 episode_return_mean은 backlog만 낮추는 정책을 선호했다.
그 결과 학습을 거의 하지 않는 정책이 선택돼 대부분 collapse했다.


5 seed 중 4개 collapse

Selected config_id=2 · selection metric = episode_return_mean

Collapse 기준 retained=0 & coverage=0 & retained-knowledge AUC=0

seed별 100/102/103/104 collapse · seed 101만 nonzero retained knowledge

원인 episode_return_mean이 낮은 backlog를 과도 선호 → no-learning policy 선택



Sweep: retention vs backlog (★ 선택 config)

12

실전적 시사점

좋은 학습 스케줄은 backlog만 줄이는 정책이 아니라, 신규 학습과 유지 학습의 균형을 만드는 정책이다.

scalar return 하나로 정책을 고르면 안 된다 → 공부 계획도 '진도율' 한 숫자가 아니라 범위·기억·밀린양을 함께 보고 평가한다

backlog가 낮다고 좋은 전략은 아니다 → '밀린 복습 0'이어도 새로 배운 게 없으면 좋은 학습이 아니다

coverage와 retained knowledge를 함께 봐야 한다 → 얼마나 넓게 배웠고(범위) 얼마나 오래 남는지(기억)를 동시에 점검한다

학습과 유지의 균형을 강제해야 한다 → 플래너에 '하루 최소 신규 학습량'과 '복습량'을 함께 목표로 설정한다

복습 밀린 양(backlog)만 줄이도록 최적화하면, 실제로는 아무것도 배우지 않는 정책이 선택될 수 있다.

13

한계와 타당성 위협

정책 우열을 확정한 결과가 아니며, simulator-reward 설계의 영향을 강하게 받는다.

■ Simulator validity

synthetic simulator 사용, 외부 learner dataset 없음
실제 학습자 행동을 완전히 반영하진 못함
“이 simulator에서의 정책 비교”로 해석해야 함

■ Reward misspecification

episode return(scalar)은 backlog 감소를 과도 선호
selected DQN: return $\uparrow$ 이나 retention-coverage 붕괴
reward/selection metric이 학습 품질과 어긋남

■ Strong baseline

greedy_immediate_gain이 retained-AUC에서 더 강함
“DQN이 baseline보다 우수” 결론은 성립 안 함
기여는 성능 우위보다 실패 모드 분석에 가까움

■ Future improvement

min coverage / retained-knowledge constraint selection
multi-objective 또는 constrained RL
실제 learner log / literature 기반 calibration
action granularity 확장 (4×15 분 고정 완화)

THANK YOU

강화학습 프로젝트

Study Scheduler RL

강화학습 기반 학습 스케줄러

핵심 결론

DQN은 episode return 최적화엔 성공했지만, 실제 학습 품질(retention·coverage)에선 실패할 수 있었다

핵심 발견: 좋은 scalar return과 좋은 학습 스케줄이 같지 않을 수 있다

study scheduling에서는 reward·selection metric 설계 자체가 핵심 연구 문제다

핵심 기여 DQN의 승리가 아니라, 학습 스케줄링 RL의 collapse failure mode를 구조적으로 드러낸 것